Actividad 4. Feature engineering avanzado, prevención de data leakage, auditoría de sesgos y documentación

Descargar el siguiente dataset:

https://drive.google.com/file/d/1Od_naN-d1B_mjJeIMDIL1dTvHEDX9PO6/view?usp=drive_link

El objetivo es predecir el ingreso anual de cada persona (income) a partir de sus características (edad, horas trabajadas por semana, nivel educativo, tipo de empleador, estado civil, sexo, raza y si nació en EE. UU.).

Parte 1: feature engineering avanzado y prevención de data leakage

a. Analizar la distribución de la target (histograma y skewness). Si aplica, realizar una de las transformaciones vistas en clase (log, Box-Cox o Yeo-Johnson) y explicar cuál se eligió y por qué. Comparar la distribución de la target original con la transformada.
b. Armar un modelo de regresión lineal que implemente k-fold cross validation sin data leakage.
c. Si aplica, evaluar el MAE del modelo entrenado con la target original y con la target transformada. Comentar los resultados.

Parte 2: auditoría de sesgos y documentación

a. Evaluar el rendimiento del modelo final considerando al menos una variable sensible (por ejemplo, sex o race). Calcular métricas de error (como MAE) por subgrupo y analizar si existen disparidades o sesgos en las predicciones.
b. Redactar una Model Card breve para el modelo final entrenado, que indique el propósito, entradas/salidas, métricas de desempeño global y por subgrupo según las variables sensibles analizadas, y limitaciones de uso.

Forma de entrega

Enlace a una notebook en un repositorio de acceso público. *Lo importante es que el código esté ejecutado* (que muestre la salida).

Evaluación

- Se evaluará que se haya respetado la consigna y que haya una interpretación adecuada de los resultados.
- Cada respuesta debe estar justificada mediante evidencia obtenida a partir de las herramientas y métricas utilizadas.